CENTRO PAULA SOUZA

GOVERNO DE SÃO PAULO

FACULDADE DE TECNOLOGIA DE FRANCA
“Dr. THOMAZ NOVELINO”

TECNOLOGIA EM DESENVOLVIMENTO DE SOFTWARE MULTIPLATAFORMA – 6º Semestre - Noturno

DÍMERSON VICENTE FERREIRA

GABRIEL ANDRADE ALEIXO

URIEL MONTE PAZ DE ARAÚJO

VITOR SIQUEIRA SIMEÃO

MINERAÇÃO DE DADOS

PROFa. Dra. JAQUELINE BRIGLADORI PUGLIESI

Atividade - Pré-processamento do PI

FRANCA/SP
2026

PRÉ-PROCESSAMENTO E SELEÇÃO DE ATRIBUTOS

1. INTRODUÇÃO:

Projeto: Gestão inteligente de estoque e previsão de demanda.

Objetivo: prever unidades vendidas por produto/dia e investigar o compromisso entre erro e número de atributos. A base Online Retail II (Chen, 2012, UCI) registra transações de varejo britânico de 2009–2011, em GBP. Fonte: UCI Online Retail II; DOI 10.24432/C5CG6D; licença CC BY 4.0, com atribuição. Não utilizamos os dados do sistema Bling, dados de clientes do projeto nem vendas sintéticas até 2026. Este estudo é supervisionado (regressão); não reavalia os clusters ou o classificador do sistema.

2. PRÉ-PROCESSAMENTO E EXPLORAÇÃO DOS DADOS

No arquivo: online_retail_II.xlsx, duas planilhas, oito campos originais. Invoice identifica a transação; StockCode, o produto; Description, sua descrição; Quantity é a quantidade; InvoiceDate, a data/hora; Price, o preço em GBP; Customer ID identifica o cliente; Country, o país. Identificadores não são variáveis quantitativas contínuas.

Normalização de espaços e códigos; validação de identificadores, datas e números finitos; remoção sequencial de cancelamentos/devoluções, preços ou quantidades não positivos, descrição vazia, códigos administrativos e duplicatas operacionais.

A primeira regra aplicável contabiliza cada exclusão uma única vez.

A chave de duplicidade inclui fatura, SKU, descrição, quantidade, timestamp, preço e país, sem Customer ID: é uma hipótese operacional, não prova de erro na origem. Customer ID ausente não exclui venda e o identificador não é armazenado nos artefatos.

Etapa (exclusiva)	Linhas
Lidas	**1.067.371**
Inválidas (identificador/data/número)	**0**
Cancelamentos/devoluções	**22.951**
Quantidade/preço não positivo	**2.750**
Descrição ausente (após filtros anteriores)	**0**
Códigos administrativos	**4.257**
Duplicatas operacionais	**33.669**
Aceitas	**1.003.744**
Excluídas (total)	**63.627**

Campo original	Ausentes antes da limpeza
Invoice	**0**
StockCode	**0**
Description	**4382**
Quantity	**0**
InvoiceDate	**0**
Price	**0**
Customer ID	**243007**
Country	**0**

As ausências acima podem se sobrepor às demais regras. Uma descrição ausente pode ter sido excluída antes por quantidade não positiva; por isso a exclusão exclusiva por descrição pode ser zero, apesar de haver descrições ausentes no arquivo.

Agregação por SKU e dia: soma de quantidades e receita.

A data é a data civil registrada na fonte britânica, sem deslocamento para o fuso brasileiro. Após limpar: 4737 SKUs, 530154 pares produto/dia, 739 dias de calendário, período 2009-12-01 a 2011-12-09.

Os dias sem transação são preenchidos com zero para a grade dos produtos avaliados. Isso assume ausência de venda registrada, não ausência de procura; antes da primeira venda pode representar item ainda não lançado.

As estatísticas descritivas desta seção cobrem a base inteira; não são usadas para ajustar limiares, normalização, seleção ou treinamento.

Estatística	Unidades por dia com venda
count	**530.154,0000**
mean	**21,1042**
std	**179,8586**
min	**1,0000**
50%	**6,0000**
90%	**44,0000**
99%	**222,0000**
max	**80.995,0000**

País (linhas aceitas)	Linhas
United Kingdom	**923.739**
EIRE	**17.125**
Germany	**15.791**
France	**13.165**
Netherlands	**4.981**
Spain	**3.563**
Switzerland	**3.068**
Belgium	**2.911**
Portugal	**2.410**
Australia	**1.783**

Outliers não foram cortados: vendas em lote podem ser legítimas.

A distribuição assimétrica motiva MAE, RMSE e WAPE. Imputação de lags indisponíveis não foi usada: os primeiros 28 dias são removidos. A árvore não requer padronização; escalas diferentes não justificam aplicar StandardScaler neste modelo. Preço, receita do dia, estoque simulado e Customer ID não entram no modelo. Diferenças contra contagens do banco podem ocorrer: esta limpeza exige descrição válida em cada venda e usa exclusões sequenciais; não reutiliza o filtro de product_id da carga operacional.

3. DIVISÃO EM CONJUNTO DE TREINAMENTO E TESTE

Corte cronológico, sem embaralhamento. Seleção de até 200 produtos de maior volume exclusivamente até 2011-11-09; desempate por SKU. Foram selecionados 200 produtos, cobrindo 41.41% das unidades do período de treino. A avaliação não representa todo o catálogo ou produtos novos.

Treino com atributos completos: 2009-12-29 a 2011-11-09, 136200 exemplos. Teste: 2011-11-10 a 2011-12-09, 6000 pares produto/dia (30 dias). Na grade do treino, 47.56% dos alvos são zero.

Origem fixa: o histórico observado termina no corte. A previsão dos 30 dias é recursiva; lags futuros usam previsões anteriores, nunca vendas reais do teste. Seleção de produtos e atributos ocorre antes de consultar os alvos de teste. Quantidade de atributos k=4 e hiperparâmetros são definidos previamente, sem busca no teste. Não há validação interna adicional; se esta comparação orientar ajustes futuros, será necessário outro holdout ou backtesting aninhado.

4. TREINAMENTO E AVALIAÇÃO DO MODELO INICIAL

HistGradientBoostingRegressor, perda Poisson, 180 iterações, 31 folhas, learning_rate=0,08, regularização L2=0,1, random_state=42 e early_stopping=False. A tarefa é regressão de vendas não negativas. Os oito atributos são product_code (SKU codificado), day_of_week, month, lag_1, lag_7, lag_14, rolling_7 e rolling_28. Lags e médias móveis são calculados apenas sobre o passado, com shift(1). O código do produto é ordinal por implementação, uma limitação a comparar futuramente com codificação categórica.

Referência: naive sazonal repete a última semana observada durante os 30 dias. MAE e RMSE têm unidade unidades/produto/dia; WAPE = 100 × soma dos erros absolutos / soma das vendas; bias = média(previsto − real). WAPE não é percentual de acerto. Não usamos MAPE por haver zeros.

Modelo	MAE	RMSE	WAPE (%)	Bias
Naive sazonal	49,5863	147,0022	121,5351	6,4147
Inicial: 8 atributos	44,5385	101,4476	109,1630	12,5263

5. SELEÇÃO DE ATRIBUTOS

Método de filtro: informação mútua com o alvo, estimada somente em uma amostra reprodutível de até 20.000 exemplos do treino. Calendário e código do produto são tratados como discretos pelo seletor. Mantêm-se os quatro maiores escores (k definido previamente); desempate pelo nome. O escore não tem interpretação causal, pode favorecer identificadores e não mede redundância conjunta entre lags correlacionados.

Atributo	Informação mútua (treino)	Selecionado
product_code	0,3191	Sim
lag_7	0,2100	Sim
rolling_7	0,2021	Sim
rolling_28	0,1912	Sim
lag_14	0,1870	Não
day_of_week	0,1308	Não
lag_1	0,1115	Não
month	0,0201	Não

Selecionados: product_code, lag_7, rolling_7, rolling_28. Nenhuma receita contemporânea ou venda futura é fornecida como preditor.

6. TREINAMENTO E AVALIAÇÃO DO MODELO COM SELEÇÃO DE ATRIBUTOS

Novo modelo, mesmos hiperparâmetros, produtos, datas, alvos e protocolo recursivo. Somente as colunas de entrada mudam. Ambos são ajustados exclusivamente no treino, sem publicação no banco.

Modelo	Atributos	MAE	RMSE	WAPE (%)	Treino (s)
Inicial	8	44,5385	101,4476	109,1630	2,2232
Seleção	4	44,8439	97,0768	109,9116	0,5814

O WAPE aumentou: diferença seleção − inicial = +0.7486 pontos percentuais. O tempo é uma medição nesta máquina, não benchmark controlado.



WAPE no mesmo teste temporal; menor é melhor. Não é acurácia.

7. DISCUSSÃO DOS RESULTADOS

A redução de 8 para 4 atributos diminui a dimensionalidade em 50%, mas não garante maior precisão ou interpretabilidade causal. Nesta execução o WAPE aumentou em relação ao modelo completo. Comparar também o naive: uma IA mais complexa não é automaticamente melhor. A escolha do modelo para produção exige avaliação independente adicional, e não seleção oportunista pelo mesmo teste.

Neste teste, o naive obteve WAPE de 121.54%, o modelo inicial 109.16% e a seleção 109.91%. O RMSE passou de 101.45 para 97.08; a MAE passou de 44.54 para 44.84. WAPE acima de 100% significa que a soma dos erros absolutos excedeu o volume vendido, não uma acurácia negativa. Assim, o desempenho absoluto é insuficiente para recomendar compras automaticamente, embora os dois modelos superem o naive em MAE neste recorte.

O identificador do produto liderou a informação mútua, seguido de informações do histórico recente. Isso permite diferenciar séries conhecidas, mas não generalizar diretamente para novos SKUs. A retirada de day_of_week limita a representação explícita da sazonalidade semanal: na série agregada, há dias sem vendas e a versão reduzida tende a suavizá-los. Essa é uma interpretação descritiva, não prova causal.

Principais limites: uma única janela temporal, demanda de fim de ano, base antiga e de outro país, foco em itens de alto volume, vendas no atacado, possíveis rupturas não observadas e política de duplicidade. A observação final de 09/12/2011 pode representar dia incompleto. A informação mútua é univariada e pode reter atributos redundantes. Picos elevam RMSE e WAPE; a recursão acumula erros. Resultados sobre vendas observadas não medem demanda perdida por ruptura. Não há garantia de transferência para uma empresa brasileira; GBP não foi convertido artificialmente em R$.

8. CONCLUSÃO

Foi executado um fluxo reproduzível de limpeza auditada, exploração, geração de atributos defasados, separação temporal, treinamento e comparação com seleção de atributos. A comparação documenta o efeito medido, sem pressupor melhoria. A entrega atende ao estudo de pré-processamento e seleção; não substitui a homologação da IA operacional. Próximos passos: backtesting em várias origens, seleção conjunta dentro de validação temporal, modelagem da intermitência e avaliação em dados reais recentes. A base e os modelos publicados no sistema não foram alterados.

REPRODUÇÃO E REFERÊNCIAS

https://github.com/FatecFranca/DSM-G05-PI6-2026-2/tree/main/docs/entregas/pre-processamento